

Trabalho 1 — Aquisição de Dados

Fase 1 de um projeto que atravessa toda a disciplina

1. Contexto e Propósito

Esta disciplina é organizada como um **projeto contínuo**. A base de dados que o seu grupo coletar neste primeiro trabalho será a **mesma** utilizada nas fases seguintes do semestre — análise exploratória (EDA), storytelling, classificação, regressão, séries temporais e agrupamento. Em outras palavras, vocês não estão entregando uma tarefa isolada: estão **construindo a fundação de todo o trabalho que virá**.

Por isso, a qualidade e a riqueza da coleta importam muito. Uma base rasa ou mal documentada agora se tornará um obstáculo recorrente nas próximas fases; uma base sólida e bem compreendida será um trampolim.

Flexibilidade ao longo do semestre

A base poderá ser **ampliada** (novas fontes, novas variáveis) nas fases futuras, à medida que cada técnica exigir. Mudanças de **tema** também são possíveis, desde que **acordadas previamente com o professor**. Não é preciso, nesta fase, garantir que a base resolva todas as fases futuras — mas quanto mais versátil ela for, menos retrabalho vocês terão.

2. Objetivo do Trabalho

Coletar, integrar e documentar uma base de dados própria, sobre um tema de livre escolha do grupo, combinando **pelo menos duas fontes heterogêneas de aquisição**: no mínimo uma **API web** e no mínimo uma **coleta direta de HTML (web scraping)**. As fontes devem ser **integradas** em uma base coerente, e todo o processo deve ser reproduzível e devidamente documentado.

3. Requisitos Obrigatórios

Para que o trabalho seja aceito, a entrega deve satisfazer todos os requisitos abaixo.

3.1 Fontes e métodos de aquisição

- No mínimo **duas fontes** de dados distintas.
- Ao menos uma coletada via **API** (pública ou autenticada).
- Ao menos uma coletada via **web scraping de HTML** (read_html, BeautifulSoup ou, se justificado, navegador automatizado).

3.2 Integração real das fontes

As fontes não podem ser entregues como duas tabelas soltas lado a lado. Elas devem se **cruzar em pelo menos um ponto** — uma chave comum que permita uni-las (um join), enriquecer uma com a outra, ou compor uma visão que nenhuma das fontes tinha sozinha. O relatório deve explicar qual foi a chave de integração e como o casamento foi feito (incluindo o tratamento de divergências, como acentos, maiúsculas e grafias diferentes).

3.3 Preservação do dado bruto

- Entregar os arquivos **crus**, exatamente como vieram de cada fonte, *antes* de qualquer limpeza.
- Entregar também a base **tratada** (integrada e limpa), claramente separada do bruto.

3.4 Registro de proveniência

Manter um registro que, para cada fonte, informe: **de onde** (URL exata), **quando** (data/hora da coleta), e **como** (método e parâmetros). Esse registro torna a coleta auditável e reproduzível.

3.5 Postura ética e legal

- Verificar e respeitar o **robots.txt** de cada site raspado; relatar o que foi verificado.
- Identificar a **licença ou os termos de uso** de cada fonte e discutir se o uso pretendido é permitido.
- Se houver **dados pessoais**, discutir as implicações de LGPD e aplicar minimização/anonimização quando cabível.
- Não sobrecarregar servidores: usar pausas entre requisições e coletar apenas o necessário.

3.6 Volume mínimo

A base deve ter **substância suficiente** para sustentar as análises futuras. Não fixamos um número único, porque o volume adequado depende do tema — mas o piso deve ser **acordado com o professor** na aprovação do tema. Como referência inicial, pense em algo na ordem de *centenas de linhas e uma dezena de colunas*, ajustável conforme a natureza dos dados.

4. O Que NÃO Cumpre o Trabalho

Para evitar mal-entendidos sobre o espírito da tarefa:

- Baixar um **dataset pronto** (Kaggle, UCI, um CSV único já montado) **não é aquisição** — o trabalho é justamente construir a base a partir de fontes que não vieram prontas.
- Usar **apenas APIs**, sem nenhum scraping, não cumpre o requisito 3.1 — e vice-versa.
- Duas fontes que **não se integram** (tabelas soltas) não cumprem o requisito 3.2.
- Entregar só a base tratada, **sem o bruto**, não cumpre o requisito 3.3.

5. Entregáveis

O grupo deve entregar um único pacote (repositório ou arquivo compactado) contendo:

Artefato	Descrição
Notebook de coleta	Jupyter Notebook reproduzível, com o código de aquisição de cada fonte, a integração e a limpeza, comentado.
Dados brutos	Os arquivos crus de cada fonte, exatamente como coletados, em uma pasta dados_brutos/.
Base tratada	A base final integrada e limpa (formato à escolha: CSV ou, preferencialmente, Parquet).
Registro de proveniência	O log de onde/quando/como cada dado foi coletado.
Dataset card	A ficha da base preenchida (modelo no Apêndice A).

6. Formato, Grupos e Prazos

- Grupos de **3 a 4 integrantes**.

- Tema **aprovado previamente** pelo professor (envio do tema e das fontes pretendidas até a data combinada).
- Prazo de entrega: **10/09/26**
- Forma de entrega: **ColabWeb**.

7. Recomendações Práticas

- Escolham o tema pensando no que *dá gosto de analisar depois* — vocês conviverão com esses dados o semestre inteiro.
- Verifiquem cedo se as fontes realmente **se cruzam**; a chave de integração é o ponto que mais costuma dar trabalho.
- Guardem o bruto **antes** de mexer em qualquer coisa. Toda limpeza é uma decisão que pode estar errada.
- Preencham a proveniência **enquanto coletam**, não no fim — reconstruir depois é penoso e impreciso.
- Uma base **mais rica em tipos de variável** (categóricas, numéricas contínuas, datas, texto) dará mais liberdade nas fases futuras.

Apêndice A — Modelo de Dataset Card

O **dataset card** é uma ficha padronizada que descreve a base para quem for usá-la (inclusive vocês mesmos, meses depois). Inspira-se na prática de *datasheets for datasets*. Preencham todos os campos; onde não se aplicar, escrevam “não se aplica” e por quê.

A.1 Identificação

Nome da base: *(um nome curto e descritivo)*

Grupo / integrantes: *(nomes)*

Tema e pergunta motivadora: *(que assunto a base cobre e que perguntas ela permite investigar)*

Data da coleta: *(período em que os dados foram coletados)*

A.2 Fontes e proveniência

Fonte 1 — nome e URL: *(ex.: IBGE Localidades — https://...)*

Fonte 1 — método: *(API ou scraping; endpoint/parâmetros ou seletores usados)*

Fonte 1 — licença / termos: *(licença de uso e se o uso pretendido é permitido)*

Fonte 2 — nome e URL: *(...)*

Fonte 2 — método: *(...)*

Fonte 2 — licença / termos: *(...)*

Chave de integração: *(qual campo une as fontes e como o casamento foi feito)*

A.3 Dicionário de variáveis

Descrição: *(preencher a tabela abaixo com uma linha por variável da base tratada)*

Variável	Tipo	Descrição	Unidade

Tipos sugeridos: categórica, numérica contínua, numérica discreta, data/hora, texto, booleana.

A.4 Volume e granularidade

Número de linhas / colunas: *(dimensões da base tratada)*

O que representa uma linha: *(a unidade de observação — ex.: um município, um jogo, um produto por dia)*

Cobertura: *(período, região ou universo abrangido)*

A.5 Limitações e decisões

Dados descartados: *(o que foi removido e por quê)*

Lacunas conhecidas: *(valores faltantes, vieses de cobertura, campos incompletos)*

Decisões de limpeza relevantes: *(transformações que alteraram os dados de forma significativa)*

A.6 Considerações éticas

Contém dados pessoais?: *(sim/não; se sim, como foram tratados sob a LGPD)*

Restrições de uso / redistribuição: *(o que a licença permite e proíbe)*

robots.txt verificado?: *(sim/não; o que foi encontrado)*

Apêndice B — Rubrica de Avaliação

A nota considera os eixos abaixo. O **peso de cada eixo será definido pelo professor**. Para cada eixo, os descritores indicam o que caracteriza um desempenho forte, mediano e fraco.

Eixo	Descritores de desempenho
Qualidade técnica da coleta	Forte: Código de aquisição correto e reproduzível; trata status HTTP e erros; usa paginação/parâmetros quando cabível. Mediano: Coleta funciona, mas com fragilidades (pouco tratamento de erro, passos manuais não documentados). Fraco: Coleta não reproduz, é incompleta, ou não corresponde ao que o relatório descreve.
Integração das fontes	Forte: Fontes realmente cruzadas por uma chave bem escolhida; divergências de casamento tratadas e explicadas. Mediano: Integração existe, mas com casamento parcial ou pouca análise das falhas. Fraco: Fontes soltas, sem integração real, ou junção incorreta.
Tratamento e limpeza	Forte: Limpeza justificada, tipos corretos, decisões documentadas; bruto preservado e separado do tratado. Mediano: Limpeza razoável, mas com decisões não explicadas ou tipos ainda inconsistentes. Fraco: Base tratada confusa, sem separação do bruto, ou com erros que comprometem o uso futuro.
Documentação (card + proveniência)	Forte: Dataset card completo e fiel; proveniência rastreável de todas as fontes. Mediano: Documentação presente, mas com lacunas ou imprecisões. Fraco: Card superficial ou ausente; proveniência incompleta ou irreconstruível.

Observação sobre a continuidade do projeto

Como esta base será reutilizada nas próximas fases, capriche na **documentação** e na **preservação do bruto**. São exatamente os itens que, negligenciados agora, mais custam caro lá na frente — e os que mais rapidamente se recuperam com um pouco de disciplina hoje.